

Tài liệu mẫu để kiểm thử RAG

Mục đích

Tài liệu này được tạo riêng để thực hành pipeline RAG: load PDF, extract text, chunking, embedding, lưu vector và retrieval. Nội dung có một số thông tin chính xác để kiểm tra Top-K chunk và một số thông tin cố ý không có để kiểm tra Assistant có biết từ chối hay không.

Thông tin dự án

Tên dự án là StudyMate Assistant. Mục tiêu của StudyMate là hỗ trợ sinh viên tìm thông tin trong tài liệu học tập nội bộ. Phiên bản demo dùng Python, Qdrant làm vector database và một embedding model đa ngôn ngữ.

Lịch hỗ trợ

Nhóm hỗ trợ kỹ thuật trực tuyến vào Thứ Hai, Thứ Tư và Thứ Sáu, từ 19:00 đến 21:00. Sinh viên gửi câu hỏi qua kênh StudyMate Support. Thời gian phản hồi mục tiêu là trong vòng 24 giờ làm việc.

Quy tắc sử dụng

Assistant chỉ được trả lời dựa trên context được retrieve từ tài liệu. Nếu không có chunk đủ liên quan, Assistant phải nói: “Không tìm thấy đủ thông tin trong tài liệu để trả lời câu hỏi này.” Assistant không được tự suy đoán ngày thi, học phí, điểm số hoặc thông tin cá nhân.

Chunking và retrieval

Cấu hình baseline của demo là chunk size 500 ký tự, chunk overlap 50 ký tự và Top-K bằng 5. Overlap giữ một phần nội dung ở biên giữa hai chunk để hạn chế mất ngữ cảnh. Top-K bằng 5 là điểm bắt đầu để thử nghiệm, không phải giá trị cố định tối ưu cho mọi tài liệu.

RAG và Agent

RAG dùng để tìm kiến thức trong tài liệu. Agent dùng để quyết định khi nào cần gọi RAG hoặc một tool khác. Ví dụ, câu hỏi về lịch hỗ trợ nên gọi `search_document`; yêu cầu tính 25 nhân 19 nên gọi `calculator`. LLM chỉ đề nghị tool call, còn chương trình harness mới là thành phần thực thi tool và gửi tool result về LLM.

Câu hỏi kiểm thử

1. StudyMate Assistant dùng vector database nào?
2. Nhóm hỗ trợ kỹ thuật trực tuyến vào những ngày và khung giờ nào?
3. Chunk size, overlap và Top-K baseline là bao nhiêu?
4. Học phí của khóa học là bao nhiêu? (Câu này không có đáp án trong tài liệu.)